

O modelo:

$$\log Y = \beta_0 + \beta_1 \log x + \epsilon \quad \text{onde } \epsilon \sim N(0, \sigma^2)$$

$$\text{ou } \log Y \sim \text{Normal}(\mu = \beta_0 + \beta_1 \log x; \sigma^2)$$

Em geral, estamos interessados nas propriedades estatísticas de Y e não de $\log Y$:

$$e^{\log Y} = e^{\beta_0 + \beta_1 \log x + \epsilon}$$

$$Y = e^{\beta_0 + \log x^{\beta_1} + \epsilon}$$

$$= e^{\beta_0} \cdot e^{\log x^{\beta_1}} \cdot e^{\epsilon}$$

$$= \beta_0^* \cdot x^{\beta_1} \cdot e^{\epsilon}, \quad \text{onde } \beta_0^* = e^{\beta_0}$$

↪ definitivamente **NÃO** é um modelo linear

e^{ϵ} caracteriza uma variável aleatória do tipo log-normal:

$$E(e^{\epsilon}) = e^{\sigma^2/2}$$

$$\text{e } \text{Var}(e^{\epsilon}) = (e^{\sigma^2} - 1) \cdot e^{\sigma^2}$$

Avaliando **SOMENTE**

$E(Y)$ e $\text{Var}(Y)$:

$$E(Y) = E(\beta_0^* \cdot x^{\beta_1} \cdot e^{\epsilon})$$

$$= \beta_0^* \cdot x^{\beta_1} \cdot E(e^{\epsilon})$$

$$= [\beta_0^* \cdot x^{\beta_1}] \cdot e^{\sigma^2/2}$$

$$= (\beta_0^* \cdot e^{\sigma^2/2}) \cdot x^{\beta_1}$$

$$\text{Var}(Y) = \text{Var}(\beta_0^* \cdot x^{\beta_1} \cdot e^{\epsilon})$$

$$= (\beta_0^* \cdot x^{\beta_1})^2 \cdot \text{Var}(e^{\epsilon})$$

$$= (\beta_0^* \cdot x^{\beta_1})^2 \cdot (e^{\sigma^2} - 1) \cdot e^{\sigma^2}$$

↪ comparando: $\text{Var}(Y) \propto E(Y)^2$
modelo heterocedástico

Transformação de Box-Cox : ②

$$Y_i^*(\lambda) = \begin{cases} \ln(Y_i) & , \text{ se } \lambda = 0 \\ \frac{Y_i^\lambda - 1}{\lambda} & , \text{ se } \lambda \neq 0 \end{cases}$$

o valor de λ é escolhido (ou estimado), de forma que:

$$Y_i^*(\lambda) \sim \text{Normal}(\mu; \sigma^2)$$

No caso de um modelo de regressão linear :

$$Y_i^*(\lambda) \sim \text{Normal}(\mu = \beta_0 + \beta_1 x_i; \sigma^2)$$

que é o mesmo que ajustar o modelo:

$$Y_i^*(\lambda) = \beta_0 + \beta_1 x_i + \varepsilon_i$$

$$\varepsilon_i \underset{\text{iid}}{\sim} \text{Normal}(0; \sigma^2)$$