

Capítulo 3 - O modelo de Regressão Linear Múltipla

26/01/2020

①

Variável Normal Padronizada:

$$Y \sim N(\mu; \sigma^2) \quad Z = \frac{Y - \mu}{\sigma}, \text{ ou seja } Z = \frac{Y - E(Y)}{\sqrt{\text{Var}(Y)}}$$

$$Z \sim N(0, 1) \quad : \quad \text{FR}(Z, 95\%) : 0 \pm 1,96 \approx 0 \pm 2.$$

$$\text{FR}(Z, 99,7\%) : 0 \pm 3.$$

No modelo $Y_i = x_i \beta + \epsilon_i$ onde $\epsilon_i \sim N(0, \sigma^2)$

$$Z_{\epsilon} = \frac{\epsilon_i}{\sigma}$$

Propriedades do resíduo:

$$\hat{\epsilon}_i = r_i = y_i - x_i \hat{\beta}$$

→ Forma matricial / vetor:

$$\hat{\epsilon} = Y - X \hat{\beta}$$

$$E(\hat{\epsilon}) = 0 \quad \text{e} \quad \text{Cov}(\hat{\epsilon}) = \sigma^2(I - H)$$

pg. 54

$$\text{Var}(\hat{\epsilon}_i) = \sigma^2[I - H]_{ii}$$

Tipos de resíduos padronizados:

① $Z_{r_i} = \frac{\hat{\epsilon}_i}{\hat{\sigma}}$ entretanto, sob a ótica da teoria, os resíduos NÃO são homocedásticos.

② $Z_{r_i} = \frac{\hat{\epsilon}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}$

Padronização na forma matricial:

$$Y \sim \text{Normal}(\mu; \Sigma) : E(Y) = \mu \quad \text{e} \quad \text{Cov}(Y) = \Sigma$$

$$(Y - \mu)^T \Sigma^{-1} (Y - \mu) \sim \chi^2_n \quad \text{lembrando que: } Y \sim \text{Normal}(\mu, \sigma^2)$$

$$\frac{Y - \mu}{\sigma} \sim N(0, 1)$$

$$\left(\frac{Y - \mu}{\sigma}\right)^2 \sim [N(0, 1)]^2 \sim \chi^2_1$$

Resíduo

Deletado :

$$r_{(i)} = \frac{r_i}{1 - h_{ii}}$$

Predicted Residuals Sum of Squares

$$\text{PRESS} = \sum_i r_{(i)}^2$$

Coefficiente de Determinação Preditivo

$$R_{\text{pred}}^2 = 1 - \frac{\text{PRESS}}{\text{SQ}_T}$$